

FINAL GROUP 2 ASSIGNMENT
STATISTICAL AUDIT OF AN OPEN-SOURCE PROJECT PANDAS-DEV/PANDAS

Dosen Pengampu:
Muhammad Ridho Kurniawan Pratama, S.Kom., M.T.I.



Disusun oleh:

Kelompok 2

- | | |
|----------------------------|------------|
| 1. Kevin Christman L.T. | 1519625025 |
| 2. Safani Nuraini | 1519625008 |
| 3. Fernando Iskandar Yusuf | 1519625042 |
| 4. Zaidan Alfaiz Sofyan | 1519625047 |
| 5. Ihsan Nurrahman Syauqy | 1519625037 |

SISTEM TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS NEGERI JAKARTA
ANGKATAN 2025

EXECUTIVE SUMMARY

Laporan ini menyajikan audit statistika menyeluruh terhadap repositori open-source pandas-dev/pandas, salah satu pustaka analisis data Python yang paling aktif dan berdampak luas di dunia. Analisis dilakukan menggunakan pendekatan statistika mencakup estimasi parameter, inferensi, uji hipotesis, dan simulasi komputasional. Berikut adalah temuan utama yang dapat ditindaklanjuti oleh maintainer repositori:

- Frekuensi masuknya *Issue* dan *Pull Request* baru per hari sangat fluktuatif, Mayoritas memiliki tingkat aktivitas yang rendah hingga sedang, ditandai dengan adanya 10 sampai 15 laporan per hari, tetapi ada hari di mana aktivitas repositori melonjak drastis hingga mencapai lebih dari 60 laporan per hari.
- Rasio antara *Pull Request* yang diterima (Merged) dan yang ditolak (Closed tanpa merge) cukup jauh, adanya ketimpangan proporsi yang sangat jelas, jumlah *Pull Request* yang diterima sekitar tiga hingga empat kali lipat lebih banyak dibandingkan *Pull Request* yang ditolak (95% peluang diterima), hal ini mengindikasikan bahwa repositori pandas sangat terbuka dan aktif dalam menerima integrasi dari para kontributor.
- Terdapat perbedaan signifikan secara statistik antara waktu penyelesaian issue yang ditangani Core Member dibandingkan kontributor eksternal, mengindikasikan adanya kesenjangan kapasitas review yang dapat mempengaruhi pengalaman kontributor baru.
- Estimasi berbasis Monte Carlo dengan 50.000 iterasi menunjukkan bahwa 9,05% issue berpotensi mengalami keterlambatan penyelesaian melebihi 30 hari, adanya risiko bottleneck dalam proses review repositori. penerapan MCMC dengan algoritma Metropolis-Hastings pada permasalahan alokasi beban kerja Sprint menghasilkan kombinasi issue optimal dengan total nilai dampak sebesar 132 dan tingkat utilisasi kapasitas 89,3% dari batas 1.000 jam kerja, menunjukkan bahwa pendekatan stokastik efektif digunakan sebagai basis perencanaan kontribusi yang sistematis dan efisien.
- Implementasi Bloom Filter dengan konfigurasi bit array 10.000-bit dan 5 fungsi hash independen memproses 2.000 issue unik dengan False Positive Rate sebesar 0,02% dan tanpa false negative, membuktikan efektivitasnya sebagai mekanisme deteksi duplikasi yang efisien secara komputasional. Hasil ini, bila dikaitkan dengan estimasi Poisson MLE yang menunjukkan rata-rata 14,71 issue masuk per hari, mengindikasikan bahwa repositori pandas-dev/pandas memerlukan sistem triase otomatis guna mempertahankan kualitas pengelolaan issue di tengah tingginya volume kontribusi harian.

1. DATA OVERVIEW

Data diperoleh dari repositori GitHub pandas-dev/pandas menggunakan GitHub REST API v3. Repositori ini merupakan pustaka manipulasi dan analisis data Python yang sangat populer, dengan ribuan kontributor aktif dari seluruh dunia. Berikut adalah data Overview-nya:

1. URL repositori: github.com/pandas-dev/pandas
2. Rentang tanggal data: 3 Juni 2021 – 3 Juni 2026 (5 tahun terakhir)
3. Jumlah data: 2.000 item gabungan (issues + PR(20 halaman x 100 item))
4. Cara ambil data: GitHub REST API v3 dengan pagination (100 item/halaman)
5. Keterbatasan:

- Kolom closed_at tidak tersedia untuk item open: 340 item yang masih berstatus open dan tidak memiliki waktu penutupan, sehingga analisis time-to-close hanya dapat dilakukan pada subset data yang sudah closed.
- Arah sampling descending: data diambil dengan urutan terbaru terlebih dahulu (direction: desc), sehingga dataset lebih merepresentasikan aktivitas terkini dibandingkan aktivitas historis awal.
- Batas 2.000 item: pengambilan data dibatasi pada 2.000 item terbaru. Repositori pandas-dev/pandas memiliki puluhan ribu issue dan PR secara historis, sehingga dataset ini merupakan sampel dan bukan sensus lengkap.
- Cakupan waktu 5 tahun: data hanya mencakup item yang dibuat sejak Juni 2021. Tren jangka panjang sebelum periode ini tidak tercermin dalam analisis.

2.000 Total Item Issues + PR gabungan	1.114 PR Diterima Berhasil di-merge	363 PR Ditolak Closed tanpa merge
--	--	--

2. PARAMETER ESTIMATION

A. MLE Bernoulli — Estimasi Peluang PR Diterima

Di repositori pandas-dev/pandas, setiap Pull Request (PR) pada dasarnya hanya memiliki dua kemungkinan hasil akhir: lolos dan di-merge ke basis kode utama (sukses, $x = 1$), atau ditutup begitu saja (gagal, $x = 0$). Mengingat sifatnya yang biner ini, variabel tersebut bisa kita modelkan menggunakan distribusi Bernoulli. Fokus kita di sini adalah mencari tahu seberapa besar peluang suksesnya, yang disimbolkan dengan parameter ρ . Merujuk pada rumus analitis log-likelihood Bernoulli yang dijelaskan oleh Tsun (2020, hal. 254), estimator MLE bisa didapatkan lewat persamaan ini:

$$\hat{p} = \frac{k}{n}$$

Dari pengumpulan data yang kita lakukan, tercatat ada 1.114 PR yang berhasil di-merge dari total 1.730 PR yang masuk. Jika dihitung:

$$\hat{p} = \frac{1114}{1730} = 0,6439 \approx 64,39\%$$

Angka ini cukup menarik untuk diinterpretasikan. Secara historis, lebih dari 60% PR yang diajukan ternyata diterima oleh maintainer. Hal ini menunjukkan bahwa repositori Pandas punya tingkat selektivitas yang wajar—tidak terlalu kaku sampai menolak mayoritas kontribusi, tapi juga tidak asal menerima draf tanpa adanya proses review.

B. Poisson — Estimasi Frekuensi Issue Harian

Selanjutnya, kita mengamati seberapa banyak *issue* dan PR baru yang masuk ke repositori setiap harinya. Karena datanya berupa variabel cacahan diskret yang dihitung dalam rentang waktu harian yang tetap, pendekatannya akan sangat pas jika menggunakan asumsi distribusi Poisson. Parameter yang akan kita cari λ adalah yang mewakili rata-rata jumlah kejadian per hari. Kalau kita turunkan fungsi diferensial *log-likelihood* Poisson sesuai dengan referensi Tsun (2020, hal. 254), estimator MLE yang dipakai adalah:

$$\hat{\lambda} = \bar{X} = \frac{\sum_{i=1}^n x_i}{n}$$

Setelah kita melakukan perhitungan dari data yang sudah diagregasi per hari, hasilnya:

$$\hat{\lambda} = 14,71 \text{ issue/hari}$$

Nilai ini memberi gambaran bahwa komunitas Pandas sangat aktif. Dengan rata-rata masuknya 14 sampai 15 *issue* atau PR baru setiap harinya, terlihat jelas bahwa tingkat keterlibatan penggunaanya sangat tinggi.

C. Pembaruan Bayesian — Distribusi Beta Posterior

Selain menggunakan pendekatan frekuentis (MLE) di atas, kita juga melakukan analisis Bayesian untuk melihat ketidakpastian dari estimasi nilai ρ . Sebagai langkah awal, kita menetapkan *prior* Beta(1, 1). Ini pada dasarnya adalah distribusi *uniform* yang sifatnya datar, yang berarti kita tidak memiliki asumsi bias terhadap nilai ρ manapun sebelum melihat

datanya secara langsung. Nah, begitu data observasi dimasukkan, parameter *posterior*-nya akan diperbarui mengikuti panduan dari Tsun (2020, hal. 269):

$$\alpha_{post} = k + 1, \quad \beta_{post} = m + 1$$


Karena jumlah sukses k adalah 1.114 dan gagal m adalah 616, kita mendapatkan distribusi *posterior* Beta(1115, 617) dengan rincian berikut:

$$\text{Mode} = \frac{\alpha - 1}{\alpha + \beta - 2} = 0,6439$$

$$\text{Mean} = \frac{\alpha}{\alpha + \beta} = 0,6438$$

Kalau diperhatikan, ada konvergensi di sini. Nilai mode *posterior*, mean *posterior*, dan estimasi MLE tadi berkumpul di titik yang nyaris persis sama ($\approx 0,6439$). Hal ini membuktikan bahwa pendekatan frekuentis dan Bayesian yang kita lakukan sangat konsisten. Mengingat ukuran sampel data kita tergolong besar, pengaruh asumsi awal (*prior*) menjadi tidak terasa, dan datanyalah yang memegang kendali penuh atas hasil inferensi.

D. Visualisasi Likelihood dan Pergeseran Posterior



Pada grafik di panel kiri, kita bisa melihat dengan jelas bagaimana distribusi bergeser. Awalnya bermula dari *prior*

Beta(1,1) yang datar, lalu berubah drastis menjadi *posterior* Beta(1115, 617) yang mengerucut tajam di sekitar nilai 0,64. Ini adalah bukti visual tentang seberapa kuat observasi data kita dalam memperbarui asumsi awal. Di sisi lain, panel kanan memperlihatkan kurva *log-likelihood* Bernoulli yang titik puncaknya tepat berada di $\hat{p} = 0,6439$. Kedua grafik ini saling mengonfirmasi keakuratan hasil estimasi kita.

D. Ringkasan Nilai Estimasi

Parameter	Distribusi	Nilai Estimasi	interpretasi Singkat
$\hat{p}$	Bernoulli	0,6439	Peluang PR lolos dan di- <i>merge</i>
$\hat{\lambda}$	Poisson	14,71 issue/hari	Rata-rata <i>issue</i> /PR baru per hari
α_{post}	Beta posterior	1.115	Parameter pembentuk <i>posterior</i> (sukses)
β_{post}	Beta posterior	617	Parameter pembentuk <i>posterior</i> (gagal)

3. CONFIDENCE INTERVAL

Confidence Interval — Rata-rata Frekuensi Issue Harian (Pendekatan Poisson)

Parameter target pada analisis ini adalah λ , yang merepresentasikan rata-rata jumlah *issue* baru yang masuk setiap harinya. Dengan ukuran sampel (n) yang memadai dan memenuhi syarat batas ($n > 30$), distribusi *sampling* dari λ diasumsikan konvergen menuju distribusi normal berdasarkan asas *Central Limit Theorem* (CLT). Oleh karena itu, aplikasi *Z-distribution* dinyatakan valid secara statistik. Persamaan interval kepercayaan yang digunakan mengacu pada Tsun (2020, hal. 300):

$$CI = \hat{\lambda} \pm z \cdot \frac{\sqrt{\hat{\lambda}}}{\sqrt{n}}$$

Pada karakteristik distribusi Poisson, nilai varians populasi identik dengan nilai rata-ratanya ($\sigma^2 = \lambda$). Sebagai implikasinya, estimasi standar deviasi disubstitusi menggunakan $\sqrt{\hat{\lambda}}$.

Hasil Estimasi: *Confidence Interval* 95% untuk parameter λ berada pada rentang [14,0614 ; 15,3504] *issue* per hari.

Interpretasi Frequentist: Rentang [14,0614 ; 15,3504] merupakan manifestasi dari prosedur tunggal penarikan sampel. Dalam kerangka kerja *Frequentist*, parameter λ merupakan konstanta yang bernilai tetap. Interpretasi yang akurat adalah: apabila prosedur penarikan sampel direplikasi secara tak terhingga dari populasi yang sama, maka 95% dari akumulasi interval yang terbentuk akan berhasil memuat parameter λ aktual. Interval observasi ini secara absolut telah memuat atau gagal memuat nilai sebenarnya, tanpa ada probabilitas inheren terhadap parameter di dalamnya.

Confidence Interval — Probabilitas Penerimaan PR (Pendekatan Bernoulli)

Parameter target berikutnya adalah ρ , yakni probabilitas suatu *Pull Request* disetujui dan di-merge ke dalam basis kode utama. Estimasi titik (*point estimate*) diekstraksi melalui $\hat{p} = \frac{k}{n}$ engan kalkulasi standar deviasi sampel $\sqrt{\hat{p}(1 - \hat{p})}$. Persamaan interval kepercayaan masih menggunakan model yang sama (Tsun, 2020, hal. 300):

$$CI = \hat{p} \pm z \cdot \frac{\sqrt{\hat{p}(1 - \hat{p})}}{\sqrt{n}}$$

Hasil Estimasi: *Confidence Interval* 95% untuk parameter ρ berada pada rentang [0,6214 ; 0,6665].

Interpretasi Frequentist: Rentang di atas mengindikasikan bahwa estimasi proporsi PR yang sukses berada di kisaran 62,14% hingga 66,65%. Pernyataan probabilitas tidak diatributkan langsung pada parameter, melainkan pada reliabilitas metode. Dengan kata lain: jika prosedur konstruksi interval diaplikasikan berulang pada sampel acak independen dari populasi yang sama, 95% dari interval yang terbentuk akan mencakup nilai proporsi ρ sesungguhnya. Nilai parameter tidak berfluktuasi, melainkan batas rentang interval yang bervariasi antar sampel.

Credible Interval — Probabilitas Penerimaan PR (Pendekatan Bayesian)

Sebagai komparasi analitis, estimasi turut dieksekusi menggunakan kerangka kerja Bayesian dengan penetapan probabilitas *prior* non-informatif Beta(1, 1). Asumsi *uniform* ini merepresentasikan ketiadaan bias awal terhadap nilai parameter sebelum data empiris diobservasi. Pasca-integrasi data (dengan k sebagai frekuensi sukses dari total n PR), distribusi *posterior* terdefinisi sebagai:

$$\text{Posterior} \sim \text{Beta}(\alpha, \beta) = \text{Beta}(k + 1, m + 1)$$

dengan variabel $m = n - k$ wakili jumlah PR yang tidak di-merge. Nilai *Credible Interval* kemudian dideduksi dari persentil distribusi *posterior* melalui fungsi *Percent Point Function* (PPF) Beta (Tsun, 2020, hal. 269).

Hasil Estimasi: *Credible Interval* 95% dikalkulasi pada rentang [0,6211 ; 0,6662].

Interpretasi Bayesian: Terdapat perbedaan ontologis fundamental pada paradigma ini, di mana probabilitas diformulasikan sebagai derajat keyakinan (*degree of belief*). Oleh karena itu, probabilitas dapat diatributkan secara langsung terhadap parameternya. Pernyataan yang valid adalah: berdasarkan bukti empiris dan asumsi *prior* non-informatif, terdapat keyakinan atau probabilitas sebesar 95% bahwa nilai absolut ρ (peluang PR di-merge) berada tepat di dalam rentang interval [0,6211 ; 0,6662]. Parameter ρ di sini diinterpretasikan sebagai variabel acak dengan properti distribusinya sendiri.

Komparasi Paradigma *Frequentist* vs Bayesian

Sintesis dari perbedaan mekanikal dan interpretatif antara kedua metode dijabarkan pada matriks berikut:

Aspek Analisis	Confidence Interval (Frequentist)	Credible Interval (Bayesian)
Output Estimasi	[0,6214 ; 0,6665]	[0,6211 ; 0,6662]
Karakteristik Parameter	Tetap (konstan), tidak terobservasi	Variabel acak, memiliki distribusi mandiri
Pusat Probabilitas	Pada metode/prosedur sampel jangka panjang	Pada representasi parameter itu sendiri
Justifikasi Probabilitas ke ρ	Inakurat (Tidak Berlaku)	Akurat (Dapat Diaplikasikan)
Spesifikasi <i>Prior</i>	Tidak diaplikasikan	Beta(1,1) — non-informatif

Kedua rentang estimasi menghasilkan matriks numerik yang nyaris ekuivalen. Fenomena ini merupakan indikasi langsung dari skala sampel n yang sangat besar yang mendominasi rumusan *prior* non-informatif, sehingga mencegah pergeseran bias pada distribusi *posterior*. Kendati menghasilkan limit yang identik, prinsip filosofis dan landasan interpretasi probabilitas dari kedua interval ini bersifat eksklusif dan tidak dapat disubstitusi satu sama lain.

4. HYPOTHESIS TESTING

Fase Pengujian Hipotesis Z-Test Dua Sampel Independen

Langkah 1: Menentukan H_0 H_a

Pertanyaan Riset (P2): Apakah terdapat perbedaan waktu penyelesaian (*time-to-close*) yang signifikan secara statistik antara *issue/PR* yang ditangani oleh Core Member dibandingkan Contributor eksternal pada repositori pandas-dev/pandas?

Karena variabel yang dianalisis adalah waktu (variabel kontinu), parameter yang diuji adalah Rata-rata (μ), bukan proporsi. Hipotesis dirumuskan sebagai berikut:

- $H_0: \mu_{core} = \mu_{contributor}$ (Tidak ada perbedaan rata-rata waktu penyelesaian *issue* antara Core Member dan Contributor).
- $H_a: \mu_{core} \neq \mu_{contributor}$ (Terdapat perbedaan rata-rata waktu penyelesaian *issue* antara Core Member dan Contributor).

Langkah 2: Tingkat Signifikansi

Tingkat signifikansi yang digunakan adalah $\alpha = 0,05$ (5%), sesuai dengan konvensi standar dalam penelitian statistik inferensial (Montgomery & Runger, 2014). Pengujian dilakukan dua arah (*two-tailed*) untuk mendeteksi perbedaan di kedua arah tanpa asumsi kelompok mana yang lebih cepat.

- $\alpha = 0.05$ (Menggunakan tingkat signifikansi standar 5%).

Langkah 3: Statistik Uji

Karena parameter populasi tidak diketahui namun ukuran kedua sampel jauh melampaui $n > 30$, kondisi ini memenuhi syarat Teorema Limit Pusat (Central Limit Theorem) sehingga distribusi sampling rata-rata mendekati distribusi normal. Oleh karena itu, digunakan: Z-Test Dua Sampel Independen (Two-Sample Z-Test) yaitu $Z = (\bar{x}_1 - \bar{x}_2) / \sqrt{(\sigma_1^2/n_1 + \sigma_2^2/n_2)}$

Langkah 4: Critical Region

Dengan pengujian dua arah (*two-tailed*) pada $\alpha = 0.05$, nilai kritis Z adalah ± 1.96 .

- **Aturan Keputusan:** H_0 akan ditolak jika nilai $|Z_{stat}| > 1.96$ atau jika $p\text{-value} < 0.05$.

... Statistik Core Member : $n=742$, rata-rata=120.65 jam, std=255.10
Statistik Contributor : $n=614$, rata-rata=220.16 jam, std=454.22

Dengan pengujian dua arah (*two-tailed*) pada $\alpha = 0,05$, nilai kritis Z adalah $\pm 1,96$. Aturan keputusan adalah:

- Tolak H_0 jika $|Z_{stat}| > 1,96$, atau
- Tolak H_0 jika $p\text{-value} < 0,05$
- Gagal tolak H_0 (fail to reject H_0) jika $|Z_{stat}| \leq 1,96$ dan $p\text{-value} \geq 0,05$

Terminologi yang digunakan adalah "reject H_0 " atau "fail to reject H_0 ". Frasa "accept H_0 " tidak digunakan karena secara statistik tidak tepat kegagalan menolak hipotesis nol bukan berarti hipotesis tersebut terbukti benar (Triola, 2018).

Langkah 5: Hasil

Z-Statistic : -4.8341
P-Value : 1.3376e-06
Keputusan : reject H_0

Parameter	Core Member	Contributor Eksternal	Keterangan
Jumlah sampel (n)	742	614	n_1 dan $n_2 \gg 30$ ✓

Rata-rata waktu ($\bar{x}$)	120,65 jam	220,16 jam	Selisih 99,51 jam
Standar deviasi (s)	255,10 jam	454,22 jam	Distribusi right-skewed

Hasil uji statistik (output dari fungsi `z_test_two_sample`):

Metrik	Nilai	Interpretasi
Z-Statistic	-4,8341	$ -4,8341 > 1,96 \rightarrow$ Masuk daerah tolak
P-Value	$1,3376 \times 10^{-6}$	$1,3376 \times 10^{-6} < 0,05 \rightarrow$ Tolak H_0
Keputusan	Reject H_0	Terdapat perbedaan signifikan

Langkah 6: Keputusan & Interpretasi

6.1 Keputusan Statistik

Berdasarkan hasil uji-Z Dua Sampel, nilai p-value ($1,3376 \times 10^{-6}$) jauh lebih kecil dari $\alpha = 0,05$, dan $|Z_stat| = 4,8341$ melampaui nilai kritis $\pm 1,96$. Dengan demikian, **H_0 ditolak** dengan bukti statistik yang sangat kuat. Terdapat perbedaan yang signifikan secara statistik antara rata-rata waktu penyelesaian issue Core Member (120,65 jam) dan Contributor eksternal (220,16 jam).

6.2 Interpretasi

Hasil pengujian menunjukkan bahwa rata-rata waktu penyelesaian issue oleh Core Member adalah 120,65 jam, sedangkan Contributor eksternal membutuhkan 220,16 jam, sehingga terdapat selisih sebesar 99,51 jam atau setara dengan kurang lebih 4,1 hari. Perbedaan tersebut tidak dapat dikategorikan sebagai variasi acak semata, melainkan mencerminkan adanya perbedaan mendasar dalam hal kapasitas operasional dan tingkat otorisasi akses di dalam repositori. Core Member memiliki kewenangan langsung untuk melakukan merge dan menutup issue tanpa harus melalui tahapan review yang bertingkat, sementara Contributor eksternal bergantung pada ketersediaan dan persetujuan maintainer sebelum kontribusinya dapat diproses.

Adapun nilai standar deviasi yang relatif besar pada kedua kelompok, yakni 255,10 jam untuk Core Member dan 454,22 jam untuk Contributor eksternal, mengindikasikan bahwa distribusi data waktu penyelesaian bersifat right-skewed dengan sebaran yang sangat lebar. Pola ini selaras dengan karakteristik distribusi Log-Normal maupun Eksponensial yang kerap ditemui pada data durasi dalam konteks pengembangan perangkat lunak (Herraiz et al., 2008). Meskipun demikian, kondisi tersebut tidak mengurangi kesahihan penggunaan Z-Test dalam analisis ini, sebab ukuran sampel yang besar pada kedua kelompok telah memenuhi syarat berlakunya Teorema Limit Pusat (Central Limit Theorem), yang menjamin distribusi sampling rata-rata mendekati distribusi normal.

Hasil ini juga memperoleh dukungan dari kajian teoritis yang relevan. Dabbish et al. (2012) dalam penelitiannya mengenai pola kolaborasi pada platform GitHub menyimpulkan bahwa hierarki peran serta perbedaan tingkat akses antar kontributor memiliki pengaruh yang nyata terhadap efektivitas dan kecepatan penyelesaian tugas dalam ekosistem proyek open-source

5. COMPUTATIONAL ANALYSIS

A. Monte Carlo Simulation

Probabilitas *issue* yang membutuhkan waktu penyelesaian lebih dari 30 hari diestimasi menggunakan Monte Carlo Simulation berdasarkan data historis repositori *pandas-dev/pandas*. Metode ini dipilih karena distribusi data bersifat *right-skewed* dan memiliki nilai ekstrem, sehingga pendekatan berbasis *sampling* lebih sesuai. Simulasi dilakukan dengan 50.000 sampel acak untuk menghasilkan estimasi yang merepresentasikan pola penyelesaian *issue* secara empiris.

Tabel Hasil Simulasi Monte Carlo

Parameter	Nilai	Keterangan
n iterasi	50.000	Sampling with replacement
P ($T > 30$ hari)	0,0905 (9,05%)	Estimasi probabilitas bottleneck
Ambang batas	720 Jam	Setara 30 hari kalender

Interpretasi dan Hubungan dengan RQ3

Hasil simulasi menunjukkan bahwa 9,05% *issue* membutuhkan waktu penyelesaian lebih dari 30 hari. Temuan ini menunjukkan adanya risiko bottleneck dalam proses penyelesaian *issue* dan mendukung RQ3 melalui estimasi risiko berbasis data historis.

B. Bloom Filter

Kemungkinan duplikasi *issue* dideteksi berdasarkan ID uniknya. Volume *issue* yang masuk setiap harinya sangat tinggi, sehingga struktur data probabilistik ini menawarkan solusi yang tepat karena mampu melakukan pengecekan keanggotaan data dengan kompleksitas waktu $O(k)$ konstan tanpa bergantung pada jumlah elemen yang tersimpan, dan beban query ke database utama pun dapat ditekan secara signifikan. Implementasi dilakukan menggunakan *bit array* berukuran 10.000 bit dan 5 fungsi *hash* independen, dengan memasukkan 2.000 *issue* unik untuk pengujian guna memvalidasi efektivitas konfigurasi filter yang dipilih..

Tabel Hasil Bloom Filter

Parameter	Nilai	Keterangan
Jumlah <i>issue</i> dimasukkan (n)	2.000	<i>Issue</i> unik yang diuji
Ukuran <i>bit array</i> (m)	10.000	Konfigurasi Bloom Filter
Jumlah fungsi hash (k)	5	Hash independen
<i>False Positive Rate</i> (FPR)	0,00020 (0,02%)	FPR teoretis
<i>False Negative</i>	0	Karakteristik Bloom Filter

Interpretasi Hasil Hubungan dengan RQ3

Bloom Filter berhasil memproses 2.000 *issue* dengan *False Positive Rate* sebesar 0,02% dan tanpa *false negative*. Hasil ini menunjukkan bahwa Bloom Filter efektif digunakan untuk mendeteksi kemungkinan duplikasi *issue*. Temuan ini mendukung RQ3 dalam meningkatkan efisiensi pengelolaan *issue*.

B. Markov Chain Monte Carlo (MCMC)

Distribusi alokasi beban kerja *Sprint* dieksplorasi secara stokastik melalui proses *sampling* berrantai menggunakan algoritma Metropolis-Hastings. Persoalan optimasi pemilihan kombinasi *issue* terbaik dari 30 *issue* mendesak dalam batasan kapasitas 1.000 jam kerja *maintainer* yang dikenal

sebagai *Knapsack Problem* membutuhkan pendekatan ini karena ruang solusinya bersifat kombinatorial dengan 2^{30} kemungkinan kombinasi, sehingga pencarian *exhaustive* secara komputasional tidak praktis untuk dilakukan. Dengan kemampuannya menjelajahi ruang solusi yang luas secara efisien melalui mekanisme *acceptance probability*, MCMC terbukti mampu menemukan kombinasi mendekati optimal dalam 100.000 iterasi tanpa terjebak pada solusi lokal yang suboptimal.

Tabel Hasil MCMC Knapsack

Statistik	Nilai	Keterangan
Kapasitas maksimal <i>Sprint</i>	1.000 jam	Batasan kapasitas kerja
Total beban waktu terpilih	893 jam	Utilisasi kapasitas 89,3%
Total nilai dampak	132	Skor optimasi tertinggi yang ditemukan
Jumlah iterasi	100.000	Iterasi Metropolis-Hastings

Interpretasi Hasil Hubungan dengan RQ3

MCMC menghasilkan solusi dengan total nilai dampak 132 dan total beban kerja 893 jam. Hasil ini menunjukkan bahwa MCMC mampu menemukan alokasi *issue* yang mendekati optimal secara efisien. Temuan tersebut mendukung RQ3 sebagai pendekatan untuk membantu perencanaan *Sprint* dan pengambilan keputusan proyek.

Recomendations

Guna memitigasi risiko tersebut, tim kami merumuskan tiga rekomendasi taktis dan berbasis data untuk para maintainer Pandas:

- Implementasi Triase Bertingkat: Menunjuk Triage Delegates dari komunitas eksternal senior untuk memotong hambatan komunikasi awal dan mempercepat time-to-close kontributor luar.
- Filter Duplikasi di Hulu: Mengintegrasikan struktur data Bloom Filter pada antarmuka pembuatan isu di GitHub untuk menyaring laporan duplikat secara instan dengan tingkat kesalahan (False Positive) hanya nol koma nol dua persen.

- Manajemen Sprint Berbasis MCMC Knapsack: Mengadopsi model optimasi stokastik untuk penjadwalan kerja mingguan, terbukti mampu memangkas beban kerja hingga delapan ratus sembilan puluh tiga jam di bawah batas aman kapasitas tim."